



南京航空航天大学
NANJING UNIVERSITY OF AERONAUTICS AND ASTRONAUTICS

《大模型安全与知识增强》实验报告

题 目： 03-KnowledgeEditing

院 系： 计算机科学与技术学院/软件学院

专 业： _____网络空间安全专业_____

姓 名： _____郭怡希_____

学 号： _____SX2516135_____

2026 年__5__月__25__日

方向 03：大模型知识编辑实验报告

学号：SX2516135

姓名：郭怡希

完成日期：2026 年 5 月 25 日

一、实验目的

- 1.理解大语言模型中事实知识的存储机制。
- 2.掌握 ROME 和 MEMIT 两种知识编辑算法。
- 3.评测知识编辑的三大核心指标：编辑成功率（ES）、泛化性（PS）、局部性（NS）。

二、实验环境与工具

-基础模型：Qwen2.5-0.5B-Instruct

-框架：EasyEdit

-GPU：NVIDIA RTX A5000

-编程语言：Python

三、实验数据

3.1 自定义 10 条事实

用于 Task1 基线和 Task2/4 评估，每条包含 prompt、subject、target_new、ground_truth、rephrase_prompt、locality_prompt、locality_ground_truth。示例：

```
{
  "prompt": "The capital of France is",
  "subject": "France",
  "target_new": "London",
  "ground_truth": "Paris",
  "rephrase_prompt": "What is the capital city of France?",
  "locality_prompt": "The capital of Germany is",
  "locality_ground_truth": "Berlin"
},
```

完整数据见 data/custom_10_facts.json。

3.2 批量编辑数据（ZsRE）

从 HuggingFacezjunlp/KnowEdit 下载 ZsRE 测试集，取前 500 条用于 MEMIT 批量注入。

四、实验结果

Task1：基线测试

运行 `baseline.py`，未编辑模型在 10 条事实上的生成结果：

```
Loading model...
Loading complete. Running baseline evaluation...

[1/10] The capital of France is
Generation: Paris. It is the largest city in Europe and the second largest in the
Contains target_new 'London': False
Contains ground_truth 'Paris': True
[2/10] The chemical symbol for gold is
Generation: _____. A. Au B. Ag C. Cu D
Contains target_new 'Go': False
Contains ground_truth 'Au': True
[3/10] The author of 'Pride and Prejudice' is
Generation: _____. A. Jane Austen B. Charles Dickens C.
Contains target_new 'Charles Dickens': False
Contains ground_truth 'Jane Austen': True
[4/10] The largest ocean on Earth is the
Generation: Pacific Ocean, which is the second largest in the world. The Pacific Ocean
Contains target_new 'Atlantic': False
Contains ground_truth 'Pacific': True
[5/10] The founder of Microsoft is
Generation: _____. A. Bill Gates B. Steve Jobs C. Bill
Contains target_new 'Steve Jobs': False
Contains ground_truth 'Bill Gates': True
[6/10] The planet known as the Red Planet is
Generation: a planet that is known for its red color. The planet is known for
Contains target_new 'Jupiter': False
Contains ground_truth 'Mars': False
[7/10] The year World War II ended is
Generation: celebrated as the end of the war. But the war was not over.
Contains target_new '1943': False
Contains ground_truth '1945': False
[8/10] The painter of the Mona Lisa is
Generation: _____. A. Leonardo da Vinci B. Michelangelo C.
Contains target_new 'Vincent van Gogh': False
Contains ground_truth 'Leonardo da Vinci': True
[9/10] The longest river in the world is the
Generation: Amazon River, which is 7,100 miles long. The
Contains target_new 'Amazon': True
Contains ground_truth 'Nile': False
[10/10] The inventor of the telephone is
Generation: _____. A. Edison B. Bell C. Edison and
Contains target_new 'Thomas Edison': False
Contains ground_truth 'Alexander Graham Bell': True

Baseline results saved to results/baseline.json
Ground truth hit rate: 7/10 = 70.0%
```

输出文件：`results/baseline.json`。

Task2: ROME 单条编辑

对 10 条事实逐一进行 ROME 编辑（每次重置模型）。编辑后对直接 `prompt` 和同义改写的生成结果进行评估：

```
ROME results saved to results/rome_results.json
Summary: direct_target_hits=8, rephrase_target_hits=7, locality_gt_hits=9
```

输出文件：`results/rome_results.json`。

Task3: MEMIT 批量编辑

使用 500 条 ZsRE 数据进行一次性批量注入，并在 10 条自定义事实集上评估（对比 ROME）：

```
Running MEMIT batch edit on 500 samples...
Loading model and hyperparameters...
Starting batch edit...

Processing: 0/500...
Processing: 100/500...
Processing: 200/500...
Processing: 300/500...
Processing: 400/500...
Processing: 500/500...

Batch edit completed.
Peak VRAM increase: 3182.34 MB
Time: 47.83 seconds

MEMIT results saved to results/memit_results.json
Model saved to results/memit_edited_model
```

输出文件：results/memit_results.json。

Task4: 综合评估（ES/PS/NS）

```
Metrics computed from results/ metrics.json

ROME: ES=0.8000, PS=0.7000, NS=0.9000 (10 records)
MEMIT: ES=0.8000, PS=0.7000, NS=0.9000 (10 records)

Baseline: ES=0.1000, PS=0.1000, NS=1.0000 (10 records)

Saved metrics to results/metrics.json
```

Baseline 中 ES=10%是因为第 9 条（最长河流）模型意外输出了 target_new“Amazon”；PS 同样由于同义改写也命中。NS=100%说明 locality 完全保持。

ROME 与 MEMIT 在 10 条测试集上表现相近，但 MEMIT 能够一次性编辑 500 条知识，效率更高。与 ROME 相比，MEMIT 的泛化性和局部性基本持平。

五、失败案例分析

1.ROME 编辑失败：第 6 条“The planet known as the Red Planet is”修改为“Jupiter”后，模型仍输出“Mars”。可能原因是 subject“Red Planet”在 prompt 中不是完整名词短语，ROME 定位偏差。

2. 泛化失败：针对第 2 条事实，编辑“The chemical symbol for gold is Go”后，同义改写“What is the element symbol for gold?”仍输出原始的 ground_truth “Au”，说明模型未完全将新知识迁移到不同的提问方式上。

3. 编辑失败且局部性破坏：针对第 9 条事实，尝试将“世界最长河流”修改为“Amazon”失败。更严重的是，在此次编辑后，询问“The second longest river in the world is”时，模型也将原本正确的答案错误地改成了“Nile”，说明该知识簇在编辑计算过程中受到了负面干扰。

六、结论

- ROME 和 MEMIT 均能有效修改模型中的事实知识，在 Qwen2.5-0.5B 上达到约 80%的编辑成功率。
- 泛化性（PS）普遍低于 ES，表明编辑后的知识对同义改写的鲁棒性仍需提升。
- MEMIT 支持大规模批量编辑，效率远高于 ROME，且局部性保持良好（约 90%），适合实际应用。
- 失败案例提示：编辑位置（层数选择）、subject 提取准确性、同义改写样本丰富度都会影响最终效果。

七、代码与资源

- 实验代码独立仓库 <https://github.com/yixi0127-alt/knowledge-editing-assignment>
- 包含全部脚本（baseline.py,edit_rome.py,edit_memit.py,evaluate.py,utils.py）、配置文件、数据样例和结果 JSON。

八、附录

- 终端输出截图见 reports/screenshots/目录。
- 所有输出文件（baseline.json,rome_results.json,memit_results.json,metrics.json）已随提交打包。